KCI 문헌 유사도 검사
결과 확인서

확 인

*** 유의사항**
KCI 문헌 유사도 검사에서 나타나는 유사도 수치는 단순한 자동검사 결과이므로,
문헌 간 유사여부 판단을 위해서는 반드시 해당 분야 전문가의 직접 검사가 필요함을 알려드립니다.

유사율	4%		
발급번호	00014024524	발급일자	2026.04.01 02:20
검사일자	2026.04.01 02:20		
검사명	변환요청합니다.		
검사문서	3027국방품질연구논집_제출용.hwp		
비고			

검사설정	유사율 기준 [5어절] , 인용문장 [포함] , 출처표시문장 [포함] , 목차/참고문헌 [포함]
비교범위	[KCI 논문] [학술대회 논문]

Powered by CopyKiller

유사 분석 정보(상세)

문서유사율	전체문장	동일문장	유사의심문장	인용포함문장	출처표시문장
4%	116	0	5	0	0

비교 문서 정보

번호	유사율	출처정보	비고
1	1%	[KCI 논문] KCI 논문 - 제목 : PGEM-DETR: Physics-guided enhancement mechanism for drone-based object detection in adverse visual environments - 저자 : Zhang Siyu() - 발행년 : 2026.01	
2	1%	[KCI 논문] KCI 논문 - 제목 : 해양 특화 환경을 위한 제로샷 기반 데이터 자동 라벨링 시스템 - 저자 : 이상욱(국립한밭대학교 정보통신공학과) - 발행년 : 2025.06	
3	1%	[KCI 논문] KCI 논문 - 제목 : 심층 신경망을 사용한 누운 얼굴 감지 기법 - 저자 : 박성호(숭실대학교) - 발행년 : 2024.01	
4	1%	[KCI 논문] www.jkta.or.kr - 제목 : 터널 내 돌발상황 오탐지 영상의 반복 학습을 통한 딥러닝 추론 성능의 자가 성장 효과 - 저자 : 이규범(한국건설기술연구원) - 발행년 : 2019.05	
5	1%	[KCI 논문] KCI 논문 - 제목 : 4차 산업혁명시대의 디지털 경공업 - 저자 : 허석재(단국대학교 리모델링연구소 연구교수) - 발행년 : 2021.10	
6	1%	[KCI 논문] KCI 논문 - 제목 : 딥러닝 기반 터널 영상유고감지 시스템 개발 연구 - 저자 : 신휴성(한국건설기술연구원) - 발행년 : 2017.11	
7	1%	[KCI 논문] KCI 논문 - 제목 : 딥러닝 기법에 기반한 빗속의 사람 그림 객체 인식 - 저자 : 전우진(고신대학교 의과대학) - 발행년 : 2022.12	
8	1%	[KCI 논문] KCI 논문 - 제목 : VisDrone-DET 학습데이터를 활용한 YOLO 버전별 분류 정확도 변화 비교 연구 - 저자 : 최혁주(Dept. of Electrical Engineering, Hanbat National University, Korea.) - 발행년 : 2024.12	
9	1%	[KCI 논문] KCI 논문 - 제목 : RAGA-YOLO: Enhancing global structural perception for accurate and efficient surface defect detection - 저자 : Zheng Tianyi() - 발행년 : 2026.01	
10	1%	[KCI 논문] KCI 논문 - 제목 : Research on US Traffic Signs Detection Algorithm with YOLO v8 - 저자 : 홍성혁(백석대학교) - 발행년 : 2025.04	
11	1%	[KCI 논문] KCI 논문 - 제목 : Video Vision Transformer를 이용한 벼의 수확량 예측과 Self-attention 시각화 - 저자 : 김다현(전남대학교) - 발행년 : 2023.08	
12	1%	[KCI 논문] KCI 논문 - 제목 : Novel Category Discovery in Plant Species and Disease Identification through Knowledge Distillation - 저자 : Jiuqing Dong(전북대학교) - 발행년 : 2024.07	

13	1%	[KCI 논문] KCI 논문 - 제목 : 분포형 광섬유 센싱 자료의 준실시간 모니터링을 위한 기계학습 기반 미소지진 신호 탐지 연구 - 저자 : 이수진(경북대학교) - 발행년 : 2025.11
14	1%	[KCI 논문] KCI 논문 - 제목 : 색상 기반 특징 증류를 통한 도메인 적응 식물 질병 분할 - 저자 : 장소연(고려대학교) - 발행년 : 2025.04

Powered by CopyKiller

검사대상문서	비교대상문서

문장유사율: **0%**

선택적 특징 융합을 적용한 트랜스포머 기반 소형 객체 탐지 Transformer Based Small Object Detection with Selective Feature Fusion Abstract : Small object detection in military bordersurveillance suffers from a significant bounding box precision gap when lightweight models resize high-resolution images (1920x1080) to their input resolution.

문장유사율: **0%**

RF-DETR, a state-of-the-art real-time detection transformer, achieves high recall but limited localization precision on our military border dataset, as 73% of annotated "large" objects (COCO[8] definition) become effectively small (shorter side < 32px) after resizing to 576x576.

문장유사율: **0%**

This makes the precision gap pervasive across all classes rather than confined to inherently small objects. To address this while preserving NAS-optimized decoder structure of RF-DETR, we apply two complementary techniques to the NAS-unmanaged pipeline gaps.

문장유사율: **0%**

First, Selective Cross-Attention leverages self-attention map of DINOv2 as a spatial prior to select only the top-25% small-object candidate CNN tokens for cross-attention injection into ViT features.

문장유사율: **0%**

Unlike prior CNN-ViT fusion approaches that indiscriminately merge all tokens, our selective strategy prevents background noise from diluting small-object features.

문장유사율: **0%**

Second, we replace GIoU with Normalized Wasserstein Distance (NWD) in the Hungarian matching loss - a stage where prior NWD applications have not been explored - stabilizing GT assignment for scale-sensitive objects at zero inference loss.

문장유사율: **0%**

The combined framework achieves mAP@50:95 of 0.906 with Person AP@75 of 0.713 (+4.0%) on the AIHub military border dataset(10 classes, 41,472 GT instances), while reducing total false positives by 38.8%.

문장유사율: **0%**

TensorRT FP16 benchmarks on NVIDIA AGX Orin 64GB confirm real-time deployment at 7.46ms (134 FPS) with SCA, representing only +7.0% latency overhead over RF-DETR-M (6.97ms, 143 FPS).

문장유사율: **0%**

keywords : Small Object Detection, Detection Transformer, CNN-ViT Feature Fusion, Normalized Wasserstein Distance, Military BorderSurveillance 1.

문장유사율: **0%**

서 론 객체 탐지(Object Detection)는 영상보안 감시시스템(VideoSurveillance System)에 있어 필수적으로 요구되는 기술이다.

문장유사율: **0%**

특히 카메라 또는 EO-IR 카메라 영상 데이터를 활용하여 자동으로 객체를 탐지함으로써 효율적인 군 경계를 지원하는데 활용되고 있다.

문장유사율: **0%**

군 경계감시 체계는 광범위한 감시 영역에 대하여 사람, 조류, 무인항공기, 소형선박 등의 다양한 객체를 신속하고 정확하게 탐지하는 것이 요구된다.

문장유사율: **0%**

최근 딥러닝 객체 탐지기술의 발전으로 고성능 GPU 또는 NPU를 탑재한 워크스테이션 또는 서버를 활용한 객체 탐지 시스템이 민간의 영상보안 감시뿐만 아니라 군 경계에도 적용되고 있다.

문장유사율: **35%**

또한, 엣지 컴퓨팅 환경에서 객체 탐지 시스템 구현을 위한 모델 경량화 및 최적화 연구가 활발히 진행되고 있다.

KCI 논문 | 제목 : 분포형 광섬유 센... | 저자 : 이수진(경... | 발행년 : 2025.11

제안된 방법의 유효성이 Utah FORGE 현장 자료를 통해 검증 되었지만, 다양한 지질 환경과 잡음 조건에서의 추가적인 검증이 필요하며, 실시간 처리를 위한 모델 경량화 및 최적화 연구가 필요할 것으로 보인다.

문장유사율: **0%**

객체 탐지기술은 CNN(Convolutional NeuralNetwork) 계열과 트랜스포머(Transformer) 계열 모델이 제안되고 있다.

문장유사율: **0%**

CNN 계열에서는 YOLO 계열의 모델이 주로 활용되고 있다. 최근 트랜스포머를 기반으로 하는 객체 탐지 모델로 DETR(Detection Transformer)[1]이 제안되었고, 탐지 성능을 개선하여 Deformable DETR[2], DINO[3], Co-DETR[4] 모델이 제안되었다.

문장유사율: **0%**

실시간 처리를 위하여 RT-DETR[5]와 RF-DETR[6]이 제안되어 실시간 객체 탐지에 있어 주목할 결과를 도출하였다.

문장유사율: **0%**

특히 RF-DETR[6]은 NAS(Neural Architecture Search) 구조와 DINOv2 ViT(Vision Transformer)[7]를 결합하여 COCO[8] 데이터셋 벤치마크에서 우수한 성능을 보였다.

문장유사율: **0%**

RF-DETR은 객체 탐지에 있어 IoU 기준에 따른 성능 차이가 크다. 이는 모델이 객체의 위치는 파악하지만 바운딩 박스(bounding box)의 크기와 경계를 정밀하게 반영하지 못한 결과이다.

문장유사율: **0%**

특히 소형 객체에 대해서 IoU 기준에 따른 현저한 차이가 있다. 본 논문에서는 효율적인 경계를 위하여 트랜스포머 기반의 소형 객체 탐지 모델을 제안한다.

문장유사율: **0%**

제안하는 모델은 RF-DETR의 DINOv2 백본을 활용하고 CNN-ViT융합[9] 및 선택적 교차 어텐션, 소형 객체 탐지에 적합한 손실 함수를 적용하는다. RF-DETR의 특정 블록이 소형 객체의 특징을 나타내는 것을 확인하고이를 강조하는 선택적 교차 어텐션(SCA, Selective Cross-Attention)를 적용한다.

문장유사율: **0%**

그리고 RF-DETR의 헝가리안 정합(Hungarian matching) 손실에서 GIoU를 대신하여 NWD(Normalized Wasserstein Distance)[10] 적용하는 손실 함수를 제안한다.

문장유사율: **0%**

제안하는 소형 객체 탐지 학습과 성능평가를 위하여 군 경계 실환경 데이터셋을 활용한다.

문장유사율: **0%**

GPU 워크스테이션과 온디바이스 AI 디바이스 상에서의 시험 및 성능 평가 결과 제안하는 객체 탐지 모델이 소형 객체 탐지 성능을 개선할 수 있음을 보인다.

문장유사율: **0%**

2. 원거리 소형 객체 탐지 2.1. 트랜스포머 기반 객체 탐지 DETR[1]은 트랜스포머의 self-attention과 이분 매칭을 영상 데이터의 객체 탐지에 적용하여 CNN YOLO 계열 모델에서 주로 사용하는 앵커(Anchor)와 NMS(Non-Maximum Suppression) 없는 효율적인 모델이다.

문장유사율: **0%**

Deformable DETR[2]은 변형 가능한 어텐션으로 수렴 속도와 소형 객체 성능을 개선한다. DINO[3]은 대조적 디노이징과 앵커 초기화로 COCO 데이터셋에 대하여 우수한 탐지 성능을 보인다. Co-DETR[4]은 협업적 하이브리드 할당으로 학습효율을 높이며, RT-DETR[5]은 하이브리드인코더 설계로 DETR의 실시간 처리가능성을 제시한다.

문장유사율: **0%**

RF-DETR[6]은 NAS를 통해 디코더 구조, 쿼리 수, 입력 해상도 등을 자동 탐색하여 DINOv2[7] 백본과 결합한 실시간 객체 탐지를 수행한다.

문장유사율: **0%**

2.2. 소형 객체 탐지와 NWD Wang 등[10]은 bbox(Bounding Box)를 2D 정규분포(Gaussian distribution) 모델링하고 Wasserstein-2 거리를 계산하는 NWD를 제안한다.

Powered by CopyKiller

문장유사율: **0%**

NWD는 IoU(Intersection over Union)이 극소형 객체에서 1~2화소(pixel) 오차에도 급변하는 문제를 완화하여 안정적인 거리 측정을 제공한다.

문장유사율: **0%**

Xu 등[11]은 NWD를 항공 영상 소형 객체 검출에 적용하여 유효성을 검증 하였으며, Yang 등[12]은 NWD를 DETR 계열의 손실 함수에 적용하였다.

문장유사율: **0%**

그러나 이들은 모두 헝가리안 정합(Hungarian matching) 이후의 비용(Cost or Loss) 단계에서만 NWD를 사용한다.

문장유사율: **0%**

매칭 단계에서 잘못된 GT(Ground Truth) 할당이 이루어지면이후 비용함수를 아무리 정교하게 설계하더라도 학습 신호의 품질을 개선하기 어렵다. 본 연구는 매칭 비용에 NWD를 직접 도입하는 접근을 취한다.

문장유사율: **0%**

한편, 드론 촬영 영상 환경에서의 소형 객체 탐지 벤치마크[13]도 유사한 스케일 문제를 보고하며, 본 연구의 도메인 분석과 일치하는 경향을 보인다. 2.3. CNN-ViT 특징 융합 ViT 백본의 고정 패치 크기(16x16)로 인한 소형 객체 표현한계를 보완하기 위해, CNN 분기의 고해상도 특징을 ViT 특징에 융합하는 연구가 수행되었다.

문장유사율: **0%**

ViT-Adapter[9]는 CNN 분기의 전체 토큰을 ViT 특징에 cross-attention으로 융합한다. 그러나 이 무차별적 융합은 두 가지 구조적 한계를 갖는다. 첫째, 군 경계 데이터셋 기준 이미지 면적 대비 소형 객체 총면적은 5% 미만이므로 CNN 토큰의 95% 이상이 배경 정보를 담고 있어 불필요한 연산이 발생한다.

문장유사율: **0%**

둘째, 배경 영역의 CNN 특징이 ViT 특징에 무차별적으로 주입되면 소형 객체 특징이 희석된다.

문장유사율: **0%**

Caron 등[14]은 DINO의 자기지도 학습 특성상 self-attention이 전경 객체 영역을 자연스럽게 활성화함을 보이며, DINOv2[7]는 이 특성을 계승한다.

문장유사율: **0%**

이러한 attention map은 선택적 토큰 선정의 사전 지식(prior)으로 활용될 수 있으나, CNN 토큰 선택에 적용한 연구는 탐구되지 않았다. 2.4. 소형 객체 탐지 설계 고려사항 RF-DETR[6]의 NAS가 최적화한 컴포넌트(디코더 FFN 차원, 레이어와 쿼리 수, 입력 해상도, 어텐션 윈도잉)를 수정하면 NAS 탐색의 최적성이 훼손될 수 있다.

문장유사율: **0%**

본 연구의 두 기법은 NAS가 관리하지 않는 파이프라인 간극, 즉 백본-프로젝터 사이(SCA)와 헝가리안 정합 비용만 적용하여 NAS 최적화 구조를 완전히 보존한다.

문장유사율: **0%**

RF-DETR-M의 DINOv2 ViT-S/16 백본은 16x16px 고정 패치 단위로 이미지를 처리한다. 576x576 입력에서 36x36=1,296개 토큰을 생성하지만, 군 경계 데이터의 Person 객체(원본 약 35x55px)는 리사이즈 후 약 10.5x16.5px로 축소되어 약 0.7개 패치 면적으로만 표현된다.

문장유사율: **0%**

이 극소 면적의 패치로는 객체의 경계를 정밀하게 표현할 수 없어 bbox 정밀도가 구조적으로 제한된다.

문장유사율: **0%**

이러한 해상도 한계를 극복하기 위해 CNN 분기의 고해상도 특징을 ViT 특징에 보충하는 접근을 고려할 수 있다.

문장유사율: **0%**

그러나 기존 ViT-Adapter[9]와 같이 CNN 전체 토큰을 무차별적으로 융합하면 배경 영역의 노이즈가 소형 객체의 특징을 희석시키는 부작용이 발생한다.

문장유사율: **0%**

따라서 소형 객체가 존재할 가능성이 높은 영역만 선별하여 해당 토큰만 융합하는 선택적 전략이 필요하다.

문장유사율: **0%**

3. 제안하는 소형 객체 탐지 제안하는 소형객체 탐지, SOD(Small Object Detection) 파이프라인은 Figure 1과 같다. SOD 파이프라인은 소형 객체 탐지 정확도를 개선하기 위하여 RF-DETR에 대하여 소형 객체 후보 추출(Small Object Heatmap), SCA(Selective Cross Attention)모듈, NWD(Normalized Wasserstein Distance) 모듈을 추가한 것이다.

문장유사율: **0%**

소형 객체 후보 추출은 DINOv2 백본에서 출력된 특징맵을 CNN 분기(CNN Branch)와 클래스 어텐션 맵 모듈을 결합하여 소형 객체 히트맵을 추출한다.

문장유사율: **0%**

SCA는 소형 객체 히트맵의 상위 25% 토큰을 선택하여 소형 객체의 속성을 반영하는 특징을 강화하는 교차 어텐션 처리를 하고 소형 객체 속성이 강화된 특징맵 산출하여 NAS투영 모듈로 전달한다.

문장유사율: **0%**

NWD 모듈은 RF-DETR의 정합 비용 산출을 위한 GIoU를 대신하여 NWD를 적용하여 소형 객체 위치 정확도를 개선하도록 한다.

문장유사율: **0%**

Figure 1. Pipeline of the proposed small object detection 3.1. 선택적 교차 어텐션 CNN 분기는 입력 영상에서 Conv3x3(stride 2) 3개 레이어와 Conv3x3(stride 1) 1개 레이어로 구성된다.

문장유사율: **0%**

각 단계의 레이어를 거치면서 해상도 72x72로 작아지면서 특징이 정제된 [256, 72, 72] 크기의 특징맵()을 출력한다.

문장유사율: **0%**

각 레이어의 정규화는 GroupNorm[15]을 사용하여 작은 배치(batch)에서도 안정적으로 동작한다. CNN 분기에서 추출한 고해상도 특징중 어느 영역을 ViT에 융합할지 결정하기 위해 소형 객체 히트맵 S를 생성한다.

문장유사율: **0%**

DINOv2 백본 블록 4의 특징은 소형 객체의 특징을 잘 포함하고 있다. 블록 4 클래스 어텐션 맵 생성 모듈은 DINOv2 블록 4의 클래스 토큰이 각 패치에 부여한 어텐션 가중치 맵(A)을 생성한다.

문장유사율: **0%**

CNN 분기의 특징맵과 DINOv2 블록 4어텐션 가중치 맵, A를 결합한(concat) 후 1x1 Conv와 시그모이드(Sigmoid)를 적용하여 각 위치의 소형 객체 존재 가능성을 0~1 범위로 출력한다.

문장유사율: **0%**

이 과정은 식 (1)과 같다. (1) 여기서, 는 소형 객체 히트맵이고, 와 는 각각 CNN 분기의 특징맵과 DINOv2 블록 4 어텐션 가중치 맵이다.

문장유사율: **0%**

소형 객체 히트맵 는 추론 시 Top-K 토큰 선택의 기준이 되므로, 학습 과정에서 가 실제 소형 객체 위치를 정확히 반영하도록 직접 감독이 필요하다.

문장유사율: **0%**

이를 위해 소형 GT bbox(area ≤ 1024) 중심에 가우시안 히트맵(Gaussian Heatmap)을 생성하고, 와의 차이를 Focal Loss[16]로 감독한다.

문장유사율: **0%**

보조감독 손실, 는 식 (2)와 같다. (2) , 는 각각 클래스가중치, 번째 위치에서 모델이 출력 예측 확률이다.

문장유사율: **0%**

정상적인 검출의 비용함수 반영을 억제하는 계수이다. 은 히트맵의 전체 위치 수이다.

문장유사율: **0%**

, 로 설정한다. GT 히트맵은 각 소형 객체 GT bbox 중심에 가우시안 커널로 생성하며, 커널 은 식 (3)과 같이 정의한다.

문장유사율: **0%**

(3) , 이며, 와 는 히트맵의 가로, 세로 좌표이며, , 는 소형 GT bbox(area 〈= 1024)의 중심 좌표 기준이다. , 으로 설정한다.

Powered by CopyKiller

문장유사율: **0%**

히트맵 S가 생성되면 값이 높은 상위 25% 위치의 CNN 토큰만 선택하여 ViT 특징에 융합한다.

문장유사율: **0%**

25%의 선택 비율은 평가 데이터셋의 소형 객체 면적 비율(전체 이미지 대비 약 5%)을 고려하되, 객체 주변 문맥 정보까지 포함하도록 여유를 둔 설정이다.

문장유사율: **0%**

전체 토큰 대신 상위 25%만 사용함으로써 교차 어텐션의 연산량이 약 75% 감소하고, S 값이 낮은 배경 영역의 CNN 특징이 ViT 특징에 주입되지 않아 배경 잡음에 의한 소형 객체 특징 희석을 방지한다.

문장유사율: **0%**

SCA(Selective Cross-Attention)는 CNN 분기, 소형 객체 히트맵, 선택적 교차 어텐션 으로 구성된다.

문장유사율: **0%**

SCA 모듈의 상세 구조는 Figure 2와 같다. Figure 2. Architecture of the SCA module 선택된 CNN 토큰을 키(Key)와 값(Value)으로, ViT의 전체 1,296개 토큰을 쿼리(Query)로 하여 교차 어텐션을 수행한다.

문장유사율: **0%**

Q와 K에 각각 2D 삼각 위치인코딩(sinusoidal position encoding, PE)을 추가하여 공간정보를 보존한다.

문장유사율: **0%**

교차 어텐션은 식 (4)와 (5)와 같이 스케일 내적 어텐션(Scaled Dot-Product Attention) 계산을 한다. (4) (5) 는 DINOv2 백본의 블록 4의 특징이고, 는 소형 객체의 속성을 강화한 특징맵이다.

문장유사율: **0%**

는 게이팅 파라미터로써 0.01 초기화한다. , 이다. SCA는 특징의 차원(384)을 변경하지 않으므로, 이후 NAS 프로젝터와 디코더에 대한 수정이 불필요하다.

문장유사율: **0%**

3.2. 제안하는 소형 객체 탐지 모델의 손실 함수 DETR 계열 모델은 헝가리안 정합(Hungarian matching)을 통해 예측 쿼리와 GT를 일대일 배정하며, 정합 손실 함수(Loss function)에 반영한다.

문장유사율: **29%**

RF-DETR의 정합 손실은 식 (6)과 같이 구성된다. (6) 여기서는 예측 쿼리와 GT 간의 매칭 손실이다.

KCI 논문 | 제목 : 색상 기반 특징 ... | 저자 : 장소연(고... | 발행년 : 2025.04

최종 손실 함수는 식 (6)과 같이 구성된다. □□걷걿값걍 □ □□□ 걸걷걸걿값갇□□□걷걿값 □갹걿갇걿□□□걷걿값 □갇걍갂 □□□걷걿값 □갹걿걿값 (6) 위 식에서 □□□ 걸걷걸걿값갇는 UAV 영상과 GT (ground truth)와의 cross-entropy loss이다.

문장유사율: **0%**

은 Focal Loss[16] 기반의 분류 비용을 나타내고, 은 정규화 좌표 기준의 위치 손실이고, 는 GIoU 기반의 형태 유사도 비용을 나타낸다. = 2, = 5, = 2로 각 항의가중치이다.

문장유사율: **0%**

GIoU 항은 객체 크기에 민감한 구조적 한계를 갖는다. IoU는 두 박스의 겹치는 면적을 합집합 면적으로 나누어 계산하므로, 동일한 화소 오차라도 객체가 작을수록 겹치는 면적의 비율 변화가 크게 발생한다.

문장유사율: **0%**

소형 객체에서는 미세한 위치 오차가 IoU를 급격히 하락시키는 반면, 대형 객체에서는 동일한 오차가 IoU에 거의 영향을 주지 않는다. 평가 데이터셋에서는 리사이즈 후 대부분의 객체가 소수의 ViT 패치 크기로 축소되므로, 이 불안정성이 전체 클래스에 걸쳐 발생한다.

문장유사율: **0%**

본 논문에서는 GIoU 대신 NWD를 적용한다. NWD는 bbox를 2D 가우시안 분포로 모델링하여 두 분포 간의 거리를 측정한다.

문장유사율: **0%**

bbox를 확률 분포로 변환하면 면적 비율이 아닌 분포 간 이동거리로 유사도를 측정하게 되므로, 객체 크기에 따른 민감도 차이가 완화된다.

문장유사율: **0%**

가우시안 분포의 평균과 공분산은 식 (7)과 (8)로 각각 정의한다. (7) (8) 는 가우시안 분포의 평균으로, bbox의 중심 좌표 (,)를 대입한다.

문장유사율: **0%**

는 가우시안 분포의 공분산 행렬로, 는 박스의 너비, 는 높이를 나타낸다. (9) 는 두 가우시안 분포 간의 Wasserstein 거리이다.

문장유사율: **0%**

와 는 각각 예측 bbox와 GT의 bbox를 모델링한 가우시안 분포의 평균을 나타내고, 와 는 각각의 표준편차 벡터이다.

문장유사율: **0%**

여기서 표준편차 벡터는 =(,)이다. 첫째 항은 두 분포의 평균 간 거리를, 둘째 항은 두 분포의 형태 간 차이를 측정한다.

문장유사율: **0%**

Wasserstein 거리를 0~1 범위의 유사도로 정규화하기 위해 식 (10)의 지수 함수를 적용한다. (10) 는 식 (9)에서 산출한 에 제곱근을 취한 값이다.

문장유사율: **0%**

는 정규화 상수로 0.5이며 0에서 1 범위의 정규화 좌표 기준으로 설정한다. NWD가 1이면 두 분포가 완전히 일치하고, 0에 가까울수록 상이하다.

문장유사율: **0%**

16x16 화소 객체에서 2 화소의 양방향 이동이 발생하면 IoU는 0.62까지 급락하는 반면, NWD는 0.78을 유지하여 26% 높은 유사도를 보존한다.

문장유사율: **0%**

96x96 화소 객체에서는 동일한 2 화소 이동에도 IoU가 0.96, NWD가 0.99로 두 지표 모두 안정적이다.

문장유사율: **0%**

즉 NWD는 소형 객체에서의 급격한 유사도 하락을 완화하면서 대형 객체에서의 안정성은 그대로 유지한다.

문장유사율: **0%**

Figure 3은 16x16 객체에서의 IoU와 NWD 응답 차이를 비교한 것이다. 식 (6)의 GIoU 항을 NWD로 대체한 매칭 비용은 식 (11)과 같이 정의한다.

문장유사율: **0%**

(11) 는 NWD를 적용한 정합 비용을 나타낸다. (1 − NWD)는 식 (10)의 유사도를 비용으로 변환한것으로, 두 분포가 유사할수록 비용이 낮아진다.

문장유사율: **0%**

= 2, = 0으로 설정하여 식 (6)의 GIoU를 NWD로 대체하며, = 2와 = 5는 식 (6)과 동일하게 유지한다. Hungarian matching은 학습 시에만 동작하므로 추론 비용은 0%이며 추가 파라미터도 0개이다.

문장유사율: **0%**

Figure 3. IoU vs NWD response comparison 4. 시뮬레이션 결과 및 검토 4.1. 시험 환경 AI-Hub 군 경계작전 환경 실데이터(ID 71858)[17]와 군 경계작전 합성데이터(ID 71856)[18]를 병합한 데이터셋을 활용하여 제안하는 객체 탐지 모델의 성능을 검증한다.

문장유사율: **0%**

군 경계작전 데이터셋은 10개 클래스(Fishing_Boat, Merchant_Ship, Warship, Person, Bird, Fixed_Wing, Rotary_Wing, UAV, Leaflet, Trash_Bomb)로 구성되며, 시험(test)를 위한 영상과 bbox GT는 각각 20,172건, 41,472건이다.

문장유사율: **0%**

제안하는 객체 탐지 모델에 대하여 CNN계열의 YOLOv11[19], YOLOv12[20](N/S/M/L)와 트랜스포머 기반 RF-DETR을 비교 분석한다.

문장유사율: **0%**

RF-DETR-Base의 입력 데이터의 해상도는 576x576이다. 모델 학습을 위해서 AdamW 최적화 알고리즘 적용하고 학습율은 1e-4, 배치크기는 16, 100 세대(epoch)으로 학습한다.

Powered by CopyKiller

문장유사율: **0%**

4.2. 성능시험 결과 및 분석 학습과 시험은 RTX 5090 32GB에서 수행한다. 처리속도에 대한 비교는 RF-DETR-Base와 제안하는 모델의 성능평가 및 비교 분석한다.

문장유사율: **0%**

성능 평가는 mAP를 적용하고 시험 결과는 Table 1과 같다. mAP@50:95와 Person AP@50:95를 비교한 결과이다.

문장유사율: **0%**

mAP@50:95는 데이터셋의 모든 클래스를 비교한 결과이고 Person AP@50:95는 소형 객체인 Person 객체 탐지 결과이다.

문장유사율: **0%**

YOLOv11과 YOLOv12의 mAP@50:95는 0.825~0.874 범위이고, RF-DETR-Base는 0.902로 3~8% 우수하다. 특히, 소형 객체인 Person 클래스에서 YOLOv11과 YOLOv12가 0.29~0.389 범위이지만, RF-DETR-Base는 0.673으로 상대적으로 성능이 우수하다.

문장유사율: **0%**

CNN계열의 YOLO 모델에 비해서 트랜스포머 기반의 객체 탐지 성능이 대체로 우수함으로 확인할 수 있다.

문장유사율: **0%**

특히, Area Attention[20]을 적용한 YOLOv12가 동일 스케일의 YOLOv11 대비 동등하거나 오히려 낮은 성능을 보인다는 것이다.

문장유사율: **0%**

YOLOv12의 국소 영역 어텐션이 성능 평가대상 데이터셋과 같이 소형 객체가 많은 데이터셋에 대해서는 성능이 개선되지 않음을 확인할 수 있다.

문장유사율: **0%**

반면 RF-DETR의 DINOv2 ViT 백본은 전역 self-attention을 통해 패치 수준의 소형 객체에 대하여 상대적으로 우수한 탐지 결과를 보인다. 제안하는 SOD-SCA 그리고 SOD-SCA+NWD의 mAP@50:95 즉 모든 클래스에 대한 객체 탐지에 있어 각각 0.904, 0.906으로 RF-DETR-Base 대비 다소 성능이 개선된다.

문장유사율: **0%**

소형 객체에 대한 탐지 성능, 즉 Person AP@50:95도 각각 0.704, 0.710으로 성능이 개선됨을 확인할 수 있다.

문장유사율: **0%**

Figure 4는 평가 데이터셋의 10개 클래스에 대한 오탐지(FP, False Positive)의 원인을 중복 탐지(FP_duplicate), 배경 오탐지(FP_background), 그리고 위치 오탐지(FP_localization)으로 분류한 결과이다.

문장유사율: **0%**

중복 탐지는 하나의 객체에 대하여 중복 탐지하는 것이고, 배경 오탐지는 배경을 객체로 탐지하는 것이다.

문장유사율: **0%**

위치 오탐지는 실제 객체 근처에서 탐지하였으나, bbox의 위치가 부정확한 것으로 IoU가 0.5 미만인 것을 나타낸다. RF-DETR-Base의 오탐지는 121건이고, SOD-SCA+NWD는 74로 38.8% 감소하였으며, FP_background, FP_localization 그리고 FP_duplication은 각각 85에서 48로, FP_localization은 34에서 26으로 감소하고, FP_duplicate는 2에서 0으로 제거된다.

문장유사율: **0%**

Table 1. Performance comparison on military border dataset Model mAP @50:95 Person AP@50:95 YOLOv11-N 0.837 0.290 YOLOv11-S 0.868 0.389 YOLOv11-M 0.870 0.374 YOLOv11-L 0.874 0.380 YOLOv12-N 0.825 0.215 YOLOv12-S 0.854 0.301 YOLOv12-M 0.867 0.370 YOLOv12-L 0.870 0.369 RF-DETR-Base 0.902 0.673 SOD-SCA 0.904 0.704 SOD-SCA+NWD 0.906 0.713 Figure 5.

문장유사율: **0%**

Person detection results of RF-DETR-Base(left) and SOD-SCA(right) Figure 4. FP cause classification by experiment configuration Figure 5은 RF-DETR-Base 모델이 탐지하지 못한 Person 객체를 SOD-SCA가 탐지한 결과로 제안하는 SOD 파이프라인이 소형 객체 탐지 성능을 개선할 수 있음을 보인다.

Powered by CopyKiller

문장유사율: **0%**

SOD-SCA의 stride-8 CNN 분기가 ViT 패치 해상도로는 포착하지 못하는 소형 객체, Person 클래스 객체의 공간적 특징을 보완하여 검출기의 전경과 배경 판별력을 개선한 결과이다.

문장유사율: **0%**

4.3. 온디바이스 AI 분석 본 논문에서는 제안하는 객체 탐지 모델을 온디바이스 AI 환경에서 탐지 성능과 처리속도를 비교 분석한다.

문장유사율: **0%**

NVIDIA Jetson AGX Orin 64GB에서 TensorRT FP16 기준으로 성능과 처리속도를 비교한다. 처리속도와 탐지 성능을 비교한 결과는 Table 2에 나타낸다. RF-DETR-Base은 1 프레임 처리시간 6.97ms로 프레임율(frame rate)은 143 FPS이며, SOD-SCA+NWD는 각각 7.46ms, 134FPS로 동등한 실시간 처리를 한다.

문장유사율: **0%**

Table 2. AGX Orin TensorRT FP16 deployment analysis Model TensorRT FP16 (ms) FPS RF-DETR-Base 6.97 143.3 SOD-SCA+NWD 7.46 134.0 5. 결론 본 연구는 군 경계감시 엣지 환경에서 RF-DETR 모델의 소형 객체 bbox 정밀도를 개선하기 위한 객체 탐지 모델을 제안한다.

문장유사율: **0%**

제안하는 소형 객체 탐지 모델은 SCA와 NWD를 적용한다. SCA는 DINOv2의 self-attention map을 사전 지식으로 활용하여 경량 CNN 분기의 상위 25% 토큰만 선택적으로 ViT 특징에 교차 어텐션으로 융합한다.

문장유사율: **0%**

군 경계 실환경 및 합성 데이터를 활용하여 학습 및 시험을 통하여 탐지 성능과 처리속도를 비교분석한 결과 제안하는 소형 객체 탐지에 효율적임을 확인할 수 있다.

문장유사율: **0%**

SOD-SCA+NWD는 mAP@50:95 0.906, Person AP@50:95 0.713(+4.0%)의 성능을 보이고, 전체 FP를 121건에서 74건으로 38.8% 감소시킨다.

문장유사율: **0%**

AGX Orin 64GB에서 TensorRT FP16 기준 SOD-SCA+NWD는 7.46ms(134 FPS)로 RF-DETR와 유사한 처리속도를 보인다.

참고문헌 문장유사율: **32%**

참고문헌 1. Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020). End-to-end object detection with transformers. European Conference on Computer Vision, 213-229. https://doi.org/10.1007/978-3-030-58452-8_13 2. Zhu, X., Su, W., Lu, L., Li, B., Wang, X., & Dai, J. (2021). Deformable DETR: Deformable transformers for end-to-end object detection. International Conference on Learning Representations. https://arxiv.org/abs/2010.04159 3. Zhang, H., Li, F., Liu, S., Zhang, L., Su, H., Zhu, J., Ni, L., & Shum, H. (2023). DINO: DETR with improved denoising anchor boxes for end-to-end object detection. International Conference on Learning Representations. https://arxiv.org/abs/2203.03605 4. Zong, Z., Song, G., & Liu, Y. (2023). DETRs with collaborative hybrid assignments training. IEEE/CVF International Conference on Computer Vision, 6748-6758. https://doi.org/10.1109/ICCV51070.2023.00621 5. Zhao, Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). DETRs beat YOLOs on real-time object detection. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 16965-16974. https://doi.org/10.1109/CVPR52733.2024.01605

KCI 논문 | 제목 : PGEM-DETR: Ph... | 저자 : Zhang S... | 발행년 : 2026.01

Zhao Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). Detrs beat yolos on real-time object detection. In Proceed- ings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp.

KCI 논문 | 제목 : 해양 특화 환경을... | 저자 : 이상욱(국... | 발행년 : 2025.06

30, pp. 5998-6008, 2017. [4] Zhao Y., Lv W., Xu S., Wei J., Wang G., Dang Q., Chen J., "Detrs beat yolos on real-time object detection IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp.

KCI 논문 | 제목 : 심층 신경망을 사... | 저자 : 박성호(숭... | 발행년 : 2024.01

Zhang, H., Li, F., Liu, S., Zhang, L., Su, H., Zhu, J., Ni, L. and Shum, H. Y. (2022). DINO: DETR with improved denoising anchor boxes for end-to-end object detection.

참고문헌 문장유사율: **15%**

6. Robinson, P., Nogueira, K., & Stojanov, S. (2025). RF-DETR: Real-time detection transformer. arXiv preprint arXiv:2501.00320. https://arxiv.org/abs/2501.00320 7. Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., ... & Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. Transactions on Machine Learning Research. https://arxiv.org/abs/2304.07193 8. Lin, T., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. (2014). Microsoft COCO: Common objects in context. European Conference on Computer Vision, 740-755. https://doi.org/10.1007/978-3-319-10602-1_48 9. Chen, Z., Duan, Y., Wang, W., He, J., Lu, T., Dai, J., & Qiao, Y. (2023). Vision transformer adapter for dense predictions. International Conference on Learning Representations. https://arxiv.org/abs/2205.08534 10. Wang, J., Xu, C., Yang, W., & Yu, L. (2022). A normalized Gaussian Wasserstein distance for tiny object detection. IEEE Transactions on Geoscience and Remote Sensing, 60, 1-11. https://doi.org/10.1109/TGRS.2021.3130365

KCI 논문 | 제목 : 터널 내 돌발상황... | 저자 : 이규범(한... | 발행년 : 2019.05

20, No. 6, pp. 1161-1175. 7. Lin, T.Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., Zitnick, C.L. (2014) Microsoft coco: Common objects in context European Conference on Computer Vision.

KCI 논문 | 제목 : 4차 산업혁명시대... | 저자 : 허석재(단... | 발행년 : 2021.10

Test., 27, pp.173~182. Lin, T.Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., Zitnick, C. L. (2014) Microsoft COCO: Common Objects in Context European Conference on Computer Vision, Springer, pp.740 755.

KCI 논문 | 제목 : 딥러닝 기법에 기... | 저자 : 전우진(고... | 발행년 : 2022.12

Vision (ICCV), pp. 10012-10022, 2021. [16] Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár P., Zitnick, C.L. Microsoft coco: Common objects in context European Conference on Computer Vision, pp.

Powered by CopyKiller

참고문헌 문장유사율: **20%**

11. Xu, C., Wang, J., Yang, W., Yu, H., Yu, L., & Xia, G. (2023). Detecting tiny objects in aerial images: A normalized Wasserstein distance and a new benchmark. ISPRS Journal of Photogrammetry and Remote Sensing, 190, 79-93. https://doi.org/10.1016/j.isprsjprs.2022.06.002 12. Yang, F., Li, Q., & Zhang, X. (2024). NWD-DETR: Normalized Wasserstein distance based DETR for tiny object detection. IEEE Signal Processing Letters, 31, 1034-1038. https://doi.org/10.1109/LSP.2024.3381178 13. Zhu, P., Wen, L., Du, D., Bian, X., Fan, H., Hu, Q., & Ling, H. (2021). Detection and tracking meet drones challenge. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(11), 7380-7399. https://doi.org/10.1109/TPAMI.2021.3119563 14. Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). Emerging properties in self-supervised vision transformers. IEEE/CVF International Conference on Computer Vision, 9650-9660. https://doi.org/10.1109/ICCV48922.2021.00951 15. Wu, Y., & He, K. (2018). Group normalization. European Conference on Computer Vision, 3-19. https://doi.org/10.1007/978-3-030-01261-8_1 16. Lin, T., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. IEEE/CVF International Conference on Computer Vision, 2980-2988. https://doi.org/10.1109/ICCV.2017.324 17. AI Hub. (2024). Military border operation environment recognition dataset (ID 71858). https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71858 18. AI Hub. (2024). Military border operation environmentsynthetic dataset (ID 71856). https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71856 19. Khanam, R., & Hussain, M. (2024). YOLOv11: An overview of the key architectural enhancements. arXiv preprint arXiv:2410.17725. https://arxiv.org/abs/2410.17725 20. Tian, Y., Ye, Q., & Doermann, D. (2025). YOLOv12: Attention-centric real-time object detectors. arXiv preprint arXiv:2502.12524. https://arxiv.org/abs/2502.12524

문장유사율: **0%**

부 록 본 논문 원고 작성 과정에서 생성형 인공지능 Anthropic Claude(claude.ai)를 사용하여 문장 교정, 영문 초록 작성 및 논문 내 플로우차트 이미지 생성 보조도구로 활용하였으며, 실험 설계, 데이터 수집 및 분석, 결과 해석은 저자가 직접 수행하였다.

KCI 논문 | 제목 : VisDrone-DET ... | 저자 : 최혁주(D... | 발행년 : 2024.12

(2021) Detection and tracking meet drones challenge IEEE transactions on pattern analysis and machine intelligence, Vol. 44, No. 11, pp. 7380-7399. https://doi.org/10.1109/TPAMI.2021.3119563

KCI 논문 | 제목 : Research on U... | 저자 : 홍성혁(백... | 발행년 : 2025.04

[8] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 42(2), 318-327.

KCI 논문 | 제목 : Video Vision ... | 저자 : 김다현(전... | 발행년 : 2023.08

DOI: https://doi.org/10.48550/arXiv 2103.15691 Caron, M., Touvron, H., Misra, I., Jegou, H., Mairal, J., Bojanowski, P., Joulin, A. (2021). Emerging properties in self-supervised vision transformers International Conference on Computer Vision, 9650-9660.

Powered by CopyKiller