

선택적 특징 융합을 적용한 트랜스포머 기반 소형 객체 탐지

ISSN 2671-4744(Print)
ISSN 2671-9673(Online)

Transformer Based Small Object Detection with Selective Feature Fusion

이강민, Kang Min Lee

경성대학교, 전자공학과, 학부생
Undergraduate Student, Department of Electronic Engineering,
Kyung Sung University

박장식[†], Jang Sik Park

경성대학교, 전자공학과, 교수
Professor, Department of Electronic Engineering, Kyung Sung
University

Abstract

Small-object detection in military border surveillance suffers from a significant bounding-box precision gap when lightweight models resize high-resolution images (1920×1080 pixels) to their input resolution. RF-DETR, a state-of-the-art real-time detection transformer, achieved high recall but limited localization precision on a military border dataset because 73% of the annotated objects became effectively small after resizing to 576×576. This makes the precision gap pervasive across classes rather than being confined to inherently small objects. To address this problem while preserving the NAS-optimized decoder structure of RF-DETR, this study applied two complementary techniques to NAS-unmanaged pipeline gaps. First, Selective Cross-Attention (SCA) uses the self-attention map of DINOv2 as a spatial prior to select only the top-25% of small-object candidate CNN tokens for cross-attention injection into ViT features. Unlike prior CNN-ViT fusion approaches, which indiscriminately merge all CNN tokens, the proposed selective strategy suppresses background-dominant tokens and prevents the dilution of small-object features. Second, the Normalized Wasserstein Distance (NWD) is introduced into the Hungarian matching cost instead of the GIoU, stabilizing the GT assignment for scale-sensitive objects without the inference-time overhead. The proposed SOD-SCA+NWD framework achieves a mAP@50:95 of 0.906 and Person AP@50:95 of 0.713 on the AIHub military border dataset, which consists of 10 classes and 41,472 test GT instances. It also reduces the total number of false positives from 121 to 74, corresponding to a 38.8% reduction. TensorRT FP16 benchmarks on NVIDIA Jetson AGX Orin 64GB confirm real-time deployment at 7.46 ms, corresponding to 134.0 FPS, with only 7.0% latency overhead compared with the RF-DETR-Base.

keywords : small object detection, detection transformer, CNN-ViT feature fusion, NWD, military border surveillance

[†] Corresponding Author : Jang Sik Park

Tel : +82-51-663-4768, email : jsipark@ks.ac.kr

Department of Electronic Engineering, Kyung Sung University, 48434, 309, Suyeong-ro, Nam-gu, Busan, Korea

Received April 6th. 2026 Revised April 29th. 2026 Accepted June 30th. 2026 Published June 30th. 2026

1. 서론

객체 탐지(object detection)는 영상 보안 감시 시스템(video surveillance system)에 있어 필수적으로 요구되는 기술이다. 특히 카메라 또는 EO-IR 카메라 영상 데이터를 활용하여 자동으로 객체를 탐지함으로써 효율적인 군 경계를 지원하는 데 활용되고 있다. 군 경계 감시 체계는 광범위한 감시 영역에 대하여 사람, 조류, 무인항공기, 소형선박 등의 다양한 객체를 신속하고 정확하게 탐지하는 것이 요구된다.

최근 딥러닝 객체 탐지 기술의 발전으로 고성능 GPU(Graphic Processing Unit) 또는 NPU(Neural Processing Unit)를 탑재한 워크스테이션 또는 서버를 활용한 객체 탐지 시스템이 민간의 영상 보안 감시뿐만 아니라 군 경계에도 적용되고 있다. 또한, 엣지 컴퓨팅 환경에서 객체 탐지 시스템 구현을 위한 모델 경량화 및 최적화 연구가 활발히 진행되고 있다.

객체 탐지 기술은 CNN(Convolutional Neural Network) 계열과 트랜스포머(transformer) 계열 모델이 제안되고 있다. CNN 계열에서는 YOLO 계열의 모델이 주로 활용되고 있다. 최근 트랜스포머를 기반으로 하는 객체 탐지 모델로 DETR(Detection Transformer)이 제안되었고[1], 탐지 성능을 개선하여 Deformable DETR, DINO, Co-DETR 모델이 제안되었다[2-4]. 실시간 처리를 위하여 RT-DETR와 RF-DETR이 제안되어 실시간 객체 탐지에 있어 주목할 결과를 도출하였다[5-6]. 특히 RF-DETR은 NAS(Neural Architecture Search) 구조와 DINOv2 ViT(Vision Transformer)를 결합하여 COCO 데이터셋 벤치마크에서 우수한 성능을 보였다[6-8]. RF-DETR은 객체 탐지에 있어 GIoU 기준에 따른 성능 차이가 크다. 이는 모델이 객체의 위치는 파악하지만 바운딩 박스(bounding box)의 크기와 경계를 정밀하게 반영하지 못한 결과이다. 특히 소형 객체에 대해서 IoU 기준에 따른 현저한 차이가 있다.

본 논문에서는 효율적인 경계를 위하여 트랜스포머 기반의 소형 객체 탐지 모델을 제안한다. 제안하는 모델은 RF-DETR의 DINOv2 백본을 활용하고 CNN-ViT 융합 및 선택적 교차 어텐션(Cross-attention), 소형 객체 탐지에 적합한 손실 함수를 적용한다[9]. 제안하는 모델의 첫 번째 주안점으로는 RF-DETR의 특정 블록이 소형 객체의 특징을 나타내는 것을 확인하고 이를 강조하는 선택적 교차 어텐션(Selective Cross-Attention, SCA)을 적용하는 것이다. 두 번째는 RF-DETR의 헝가리안 정합(hungarian matching) 손실에서 GIoU를 대신하여 NWD(Normalized Wasserstein Distance)를 적용하는 손실 함수를 제안한다[10].

제안하는 소형 객체 탐지 모델(Small Object Detection, SOD)의 학습과 성능 평가를 위하여 군 경계 실환경 데이터셋과 합성 데이터셋을 활용한다. GPU 워크스테이션과 온디바이스 AI 디바이스 상에서의 시험 및 성능 평가 결과 제안하는 객체 탐지 모델이 소형 객체 탐지 성능을 개선할 수 있음을 보인다.

2. 원거리 소형 객체 탐지

2.1. 트랜스포머 기반 객체 탐지

DETR은 트랜스포머의 자기 어텐션(self-attention)과 이분 매칭을 영상 데이터의 객체 탐지에 적용하여 CNN YOLO 계열 모델에서 주로 사용하는 앵커(anchor)와 NMS(Non-Maximum Suppression) 없는 효율적인 모델이다[1]. Deformable DETR은 변형 가능한 어텐션으로 수렴 속도와 소형 객체 성능을 개선한다[2]. DINO는 대조적 디노이징과 앵커 초기화로 COCO 데이터셋에 대하여 우수한 탐지 성능을 보인다[3]. Co-DETR은 협업적 하이브리드 할당으로 학습 효율을 높이며[4], RT-DETR은 하이브리드 인코더 설계로 DETR의 실시간 처리 가능성을 제시한다[5]. RF-DETR은 NAS를 통해 디코더 구조, 쿼리 수, 입력 해상도 등을 자동 탐색하

여 DINOv2 백본과 결합한 실시간 객체 탐지를 수행한다[6-7].

2.2. 소형 객체 탐지와 NWD

Wang et al. (2021)은 BBox(Bounding Box)를 2D 정규분포(Gaussian distribution)로 모델링하고 Wasserstein-2 거리를 계산하는 NWD를 제안하였다[10]. NWD는 GIoU(Intersection over Union)가 극소형 객체에서 1~2화소(pixel) 오차에도 급격히 변동하는 문제를 완화하여 안정적인 거리 측정을 제공한다. Xu et al. (2022)은 NWD를 항공 영상 소형 객체 검출에 적용하여 유효성을 검증하였다[11]. 그러나 선행 연구들은 주로 헝가리안 정합 이후의 비용 또는 회귀 손실 단계에서 NWD를 활용하였다. 매칭 단계에서 잘못된 GT(Ground Truth) 할당이 이루어지면 이후 손실 함수를 정교하게 설계 하더라도 학습 신호의 품질을 충분히 개선하기 어렵다. 본 연구는 이러한 한계를 고려하여 NWD를 헝가리안 정합 비용에 직접 도입한다. 한편, 드론 촬영 영상 환경의 소형 객체 탐지 벤치마크도 유사한 스케일 문제를 보고하며, 이는 본 연구의 군 경계 감시 도메인 분석과 일치하는 경향을 보인다[12].

2.3. CNN-ViT 특징 융합

ViT 백본은 고정 패치 크기(16×16)를 사용하므로 입력 영상에서 작은 객체가 소수의 패치에만 대응된다. 이 경우 객체 중심은 포착되더라도 경계 정보가 충분히 표현되지 않아 BBox 정밀도가 저하될 수 있다. 이러한 한계를 보완하기 위해 CNN 분기의 고해상도 특징을 ViT 특징에 결합하는 CNN-ViT 융합 연구가 수행되었다. 대표적으로 ViT-Adapter는 CNN 분기에서 생성된 전체 토큰을 ViT 특징에 교차 어텐션으로 융합하여 조밀 예측(dense prediction) 성능을 개선하였다[9]. 그러나 군 경계 감시 영상과 같이 원거리 배경 비중이 큰 환경에서는 전체 CNN 토큰을 일괄적으로 융합하는 방식에 한계가 있다. 첫째, 전체 영상 면적 대비 소형 객체가 차지하는 비율

이 낮기 때문에 CNN 토큰의 대부분은 배경 정보를 포함한다. 이러한 토큰을 모두 ViT 특징에 주입하면 객체 탐지에 직접 기여하지 않는 배경 정보까지 함께 처리되어 연산량이 증가한다. 둘째, 배경 토큰이 소형 객체 토큰과 함께 융합되면 소형 객체의 국소 특징이 상대적으로 희석되어 위치 정밀도 개선 효과가 제한될 수 있다.

Caron et al. (2021)은 DINO의 자기지도 학습 특성상 자기 어텐션이 전경 객체 영역을 자연스럽게 활성화함을 보였으며[13], DINOv2는 이러한 특성을 계승한다[7]. 본 연구는 이 특성을 CNN 토큰 선택의 공간적 사전 지식(prior)으로 활용한다. 구체적으로 DINOv2 블록 4의 자기 어텐션 맵과 CNN 분기 특징 D_3를 결합하여 소형 객체 히트맵 S를 생성하고, S 값이 높은 상위 25% CNN 토큰만 선택하여 ViT 특징에 융합한다. 따라서 제안 방식은 CNN 특징을 단순히 추가하는 것이 아니라, 소형 객체 후보 영역에 해당하는 고해상도 특징만 선별적으로 강조하는 구조이다.

2.4. 소형 객체 탐지 설계 고려 사항

RF-DETR의 NAS가 최적화한 컴포넌트, 즉 디코더 FFN(Feed-Forward Network) 차원, 레이어와 쿼리 수, 입력 해상도, 어텐션 윈도잉을 수정하면 NAS 탐색의 최적성이 훼손될 수 있다[6]. 본 연구의 두 기법은 NAS가 직접 관리하지 않는 파이프라인 간극, 즉 백본-프로젝터 사이의 특징 융합과 헝가리안 정합 비용 산출에만 적용된다. 따라서 RF-DETR의 NAS 최적화 구조는 보존된다.

RF-DETR-Base의 DINOv2 ViT-S/16 백본은 16×16 화소 고정 패치 단위로 이미지를 처리한다. 576×576 입력에서는 36×36 , 즉 1,296개 토큰을 생성하지만, 군 경계 데이터의 Person 객체가 원본에서 약 35×55 화소 크기인 경우 리사이즈 후 약 10.5×16.5 화소로 축소되어 약 0.7개 패치 면적으로만 표현된다. 이러한 극소 면적의 패치 표현만으로는 객체의 경계를 정밀하게 표현하기 어렵기 때문에

BBox 정밀도가 구조적으로 제한된다.

이러한 해상도 한계를 극복하기 위해 CNN 분기의 고해상도 특징을 ViT 특징에 보충하는 접근을 고려할 수 있다. 그러나 기존 ViT-Adapter와 같이 CNN 전체 토큰을 무차별적으로 융합하면 배경 영역의 잡음(noise)이 소형 객체 특징을 희석시키는 부작용이 발생할 수 있다[9]. 따라서 소형 객체가 존재할 가능성이 높은 영역만 선별하여 해당 토큰만 융합하는 선택적 전략이 필요하다.

3. 제안하는 소형 객체 탐지

제안하는 소형 객체 탐지 파이프라인은 Figure 1과 같다. SOD 파이프라인은 RF-DETR에 소형 객체 후보 추출, SCA 모듈, NWD 기반 정합 비용을 추가하여 소형 객체 탐지 정확도를 개선한다.




Figure 1. Pipeline of the proposed small object detection

소형 객체 후보 추출은 DINOv2 백본에서 출력된 특징맵을 CNN 분기(CNN branch)와 클래스 어텐션 맵 모듈에 결합하여 소형 객체 히트맵을 생성한다. SCA는 소형 객체 히트맵의 상위 25% 토큰을 선택하고, 해당 토큰을 이용해 소형 객체 속성을 강화하는 교차 어텐션을 수행한다. 강화된 특징맵은 NAS 투영 모듈로 전달된다. NWD 모듈은 RF-DETR의 정합 비용 산출 과정에서 GIoU를 대신하여 NWD를 적용함으로써 소형 객체의 위치 정확도를 개선하도록 한다.

소형 객체 탐지 성능 개선을 위한 본 논문의 주안점은 Table 1과 같이 블록 4 특징 강조와 NWD 기반 비용함수이다.

Table 1. Comparison of RF-DETR and proposed object detection pipeline

Model	RF-DETR-Base	SCA+NWD (proposed)
Backbone	DINOv2 ViT-S/16	
Encoder	Non-Win + Win × 2 interleave	
Block 4 enrichment	none	Selective CNN-ViT cross-attention
Projector	Multi-scale(NAS-optimization)	
Decoder	Decoder Group × 4	
Heads	Class + Box	
Hungarian matchig cost	GIoU	NWD

첫째, 블록 4 특징 강조는 기존 ViT-Adapter에서 CNN 각 특징점 즉 토큰을 ViT 특징에 균등하게 융합하는 대신 DINOv2 자기 어텐션 맵을 소형 객체 후보 가능성이 높은 상위 25% CNN 특징만 선택적으로 융합하는 SCA 구조로 제안한다[9]. 둘째, 형가리안 정합 비용함수에 GIoU 대신 NWD를 적용하여 면적 비율이 아닌 분포 간 거리와 형태 차이로 유사도를 측정하게 되므로 객체 크기에 따른 민감도 차이를 완화함으로써 소형 객체 탐지 성능을 개선하고자 한다.

3.1. 선택적 교차 어텐션

CNN 분기는 입력 영상에서 Conv3×3(stride 2) 3개 레이어와 Conv3×3(stride 1) 1개 레이어로 구성된다. 각 단계의 레이어를 거치면서 해상도 72×72로 작아지면서 특징이 정제된 [256, 72, 72] 크기의 특징맵(D_3)을 출력한다. 각 레이어의 정규화는 GroupNorm을 사용하여 작은 배치(batch)에서도 안정적으로 동작한다[14].

CNN 분기에서 추출한 고해상도 특징 중 어느 영역을 ViT에 융합할지 결정하기 위해 소형 객체 히트맵 S를 생성한다. DINOv2 백본 블록 4의 특징은 소형 객체의 특징을 잘 포함하고 있다. 블록 4 클래스 어텐션 맵 생성 모듈은 DINOv2 블록 4의 클래스 토큰이 각 패치에 부여한 어텐션 가중치 맵을 생성한다.

CNN 분기의 D_3 특징맵과 DINOv2 블록 4 어텐션 가중치 맵을 결합(concat) 후 1×1 Conv와 시그모이드(sigmoid)를 적용하여 각 위치의 소형 객체 존재 가능성을 0~1 범위로 출력한다. 이 과정은 식 (1)과 같다.

$$S = \sigma(\text{Conv}_{1 \times 1}([D_3; A])) \quad (1)$$

여기서, S 는 소형 객체 히트맵, D_3 은 CNN 분기의 stride-8 특징맵, A 는 DINOv2 블록 4의 클래스 어텐션 가중치 맵이다. $[D_3; A]$ 는 채널 방향 결합을 의미하며, $\sigma(\cdot)$ 는 시그모이드 함수이다.

소형 객체 히트맵 S 는 추론 시 Top-K 토큰 선택의 기준이 되므로, 학습 과정에서 S 가 실제 소형 객체 위치를 정확히 반영하도록 직접 감독이 필요하다. 이를 위해 소형 GT BBox(area≤1024) 중심에 가우시안 히트맵(Gaussian heatmap)을 생성하고, S 와의 차이를 focal loss로 감독한다[15]. 보조 감독 손실, L_{aux} 는 식(2)와 같다.

$$L_{aux} = -\frac{1}{N} \sum_{i=1}^N \alpha_i (1 - p_i)^\gamma \log p_i \quad (2)$$

여기서 N 은 히트맵의 전체 위치 수, p_i 는 i 번째 위치에서 모델이 예측한 소형 객체 존재 확률, α_i 는 샘플 가중치이다. γ 는 쉬운 샘플의 손실 기여를 억제하는 초점 계수이며, 본 논문에서는 $\gamma = 2$, $\alpha_i = 0.25$ 로 설정한다. GT 히트맵은 각 소형 객체 GT BBox 중심에 가우시안 커널로 생성하며, 커널 $G(x, y)$ 은 식(3)과 같이 정의한다.

$$G(x, y) = \exp(-E_x - E_y) \quad (3)$$

$E_x = (x - c_x)^2 / 2\sigma_x^2$, $E_y = (y - c_y)^2 / 2\sigma_y^2$ 이며, 여기서 x 와 y 는 히트맵의 가로, 세로 좌표이며, c_x , c_y 는 소형 GT BBox(area≤1024)의 중심 좌표 기준이다. σ_x 와 σ_y 는 각각 가우시안 커널의 가로 및 세로 표준편차이며, BBox의 너비 w 와 높이 h 를 이용해 $\sigma_x = w/6$, $\sigma_y = h/6$ 으로 설정한다.

히트맵 S 가 생성되면 값이 높은 상위 25% 위치의 CNN 토큰만 선택하여 ViT 특징에 융합한다. 25%의 선택 비율은 평가 데이터셋의 소형 객체 면적 비율(전체 이미지 대비 약 5%)을 고려하되, 객체 주변 문맥 정보까지 포함하도록 여유를 둔 설정이다. 전체 토큰 대신 상위 25%만 사용함으로써 교차 어텐션의 연산량이 약 75% 감소하고, S 값이 낮은 배경 영역의 CNN 특징이 ViT 특징에 주입되지 않아 배경 잡음에 의한 소형 객체 특징 희석을 방지한다.

SCA는 CNN 분기, 소형 객체 히트맵, 선택적 교차 어텐션으로 구성된다. SCA 모듈의 상세 구조는 Figure 2와 같다.

선택된 CNN 토큰을 키(key)와 값(value)으로, ViT의 전체 1,296개 토큰을 쿼리(query)로 하여 교차 어텐션을 수행한다. Q와 K에는 각각 2D 삼각 위치 인코딩(Position Encoding, PE)을 추가하여 공간 정보를 보존한다. 교차 어텐션은 식(4)와 같이 스케일 내적 어텐션(scaled dot-product attention)으로 계산한다.

$$CA(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4)$$

여기서 Q 는 ViT 전체 토큰으로부터 생성된 쿼리, K 와 V 는 Top-K로 선택된 CNN 토큰으로부터 생성된 키와 값, d_k 는 키 벡터의 차원이다. $\text{softmax}(\cdot)$ 는 쿼리와 키의 유사도를 확률 분포로 정규화하는 함수이다. SCA가 적용된 특징 P_3' 는 식(5)와 같이 계산한다.

$$P_3' = P_3 + \alpha_{gate} \cdot CA(Q, K, V) \quad (5)$$

여기서 P_3 는 DINOv2 백본의 블록 4의 특징이고, P_3' 는 소형 객체의 속성을 강화한 특징맵이다. α_{gate} 는 교차 어텐션 주입 강도를 제어하는 학습

가능 게이팅 파라미터이며 0.01 초기화한다. 본 연구에서는 $Q = P_3$, $K = V = \text{TopK}(D_3, S)$ 로 정의한다. SCA는 P_3 특징의 차원(384)을 변경하지 않으므로, 이후 NAS 프로젝터와 디코더에 대한 수정이 불필요하다.

3.2. 제안하는 소형 객체 탐지 모델의 손실 함수

DETR 계열 모델은 헝가리안 정합을 통해 예측 쿼리와 GT를 일대일 배정하며, 정합 손실 함수(loss function)에 반영한다. RF-DETR의 정합 손실은 식(6)과 같이 구성된다.

$$C_{base} = \lambda_{cls} \cdot L_{focal} + \lambda_{L1} \cdot L_{L1} + \lambda_{giou} \cdot L_{GIoU} \quad (6)$$

여기서 C_{base} 는 예측 쿼리와 GT 간의 매칭 비용이다. L_{focal} 은 focal loss 기반의 분류 비용을 나타내고[15], L_{L1} 은 정규화 좌표 기준의 L_1 위치 손실이고, L_{GIoU} 는 GIoU 기반의 형태 유사도 비용을 나타낸다. 각 항의 가중치는 $\lambda_{cls} = 2$, $\lambda_{L1} = 5$, $\lambda_{giou} = 2$ 로 설정한다.

GIoU 항은 객체 크기에 민감한 구조적 한계를 갖는다. IoU는 두 박스의 겹치는 면적을 합집합 면적으로 나누어 계산하므로, 동일한 화소 오차라도 객체가 작을수록 겹치는 면적 비율의 변화가 크게 발생한다. 소형 객체에서는 미세한 위치 오차가 IoU를 급격히 하락시키는 반면, 대형 객체에서는 동일한 오차가 IoU에 상대적으로 작은 영향을 준다. 평가 데이터셋에서는 리사이즈 후 다수 객체가 소수의 ViT 패치 크기로 축소되므로, 이러한 불안정성이 여러 클래스에 걸쳐 발생한다.

본 논문에서는 GIoU 대신 NWD를 적용한다. NWD는 BBox를 2D 가우시안 분포로 모델링하여 두 분포 간의 거리를 측정한다. BBox를 확률 분포로 변환하면 면적 비율이 아닌 분포 간 이동 거리와 형태 차이로 유사도를 측정하게 되므로 객체 크기에 따른 민감도 차이가 완화된다. 가우시안 분포의 평균과 공분산은 식(7)과 식(8)로 각각 정의한다.




Figure 2. Architecture of the SCA module

$$\mu = (c_x, c_y) \quad (7)$$

$$\Sigma = \text{diag}(w^2/4, h^2/4) \quad (8)$$

여기서 μ 는 가우시안 분포의 평균으로, bbox의 중심 좌표 (c_x, c_y)를 대입한다. Σ 는 가우시안 분포의 공분산 행렬로, w 와 h 는 각각 BBox의 너비와 높이이다. $\text{diag}(\cdot)$ 는 대각 행렬을 구성하는 연산이다.

$$W_2^2 = \left| \left| \mu_A - \mu_B \right| \right|^2 + \left| \left| \sigma_A - \sigma_B \right| \right|^2 \quad (9)$$

여기서 μ_A 와 μ_B 는 각각 예측 BBox와 GT BBox를 모델링한 가우시안 분포의 평균이다. σ_A 와 σ_B 는 각 BBox의 표준편차 벡터이며, $\sigma = (w/2, h/2)$ 로 정의한다. 식(9)의 첫째 항은 두 BBox 중심 간 거리를, 둘째 항은 BBox의 크기 및 형태 차이를 측정한다.

Wasserstein 거리를 0~1 범위의 유사도로 정규화하기 위해 식(10)의 지수 함수를 적용한다.

$$NWD(A, B) = \exp\left(-\frac{W_2}{C}\right) \quad (10)$$

여기서 W_2 는 식(9)에서 산출한 W_2^2 의 제곱근이며, C 는 정규화 상수이다. 본 연구에서는 좌표가 0~1 범위로 정규화되어 있음을 고려하여 $C=0.5$ 로 설정한다. NWD가 1이면 두 분포가 완전히 일치하고, 0에 가까울수록 상이하다.

16×16 화소 객체에서 2화소의 양방향 이동이 발생하면 IoU는 0.62까지 급락하는 반면, NWD는 0.78을 유지하여 상대적으로 높은 유사도를 보존한다. 96×96 화소 객체에서는 동일한 2화소 이동에도 IoU가 0.96, NWD가 0.99로 두 지표가 모두 안정적이다. 즉 NWD는 소형 객체에서 급격한 유사도 하락을 완화하면서 대형 객체에서의 안정성도 유지한다. Figure 3은 16×16 객체에서의 IoU와 NWD 응답 차이를 비교한 것이다.




Figure 3. IoU and NWD response comparison

$$C_{NWD} = \lambda_{cls} \cdot L_{focal} + \lambda_{L1} \cdot L_{L1} + \lambda_{nwd} \cdot (1 - NWD) \quad (11)$$

여기서 C_{NWD} 는 NWD를 적용한 정합 비용을 나타낸다. $(1 - NWD)$ 는 식(10)의 유사도를 비용으로 변환한 항으로, 두 분포가 유사할수록 비용이 낮아진다. 본 연구에서는 $\lambda_{nwd} = 2$, $\lambda_{giou} = 0$ 으로 설정하여 식(6)의 GIoU를 NWD로 대체하고, $\lambda_{cls} = 2$ 와 $\lambda_{L1} = 5$ 는 기존 RF-DETR와 동일하게 유지한다. 형가리안 매칭은 학습 과정에서만 적용되기 때문에 파라미터가 추가되지 않는다.

4. 시뮬레이션 결과 및 검토

4.1. 시험 환경

제안 모델의 성능 검증에는 AI-Hub의 군 경계 실데이터와 합성데이터를 8:1:1 비율로 분할하여 통합한 데이터셋을 사용하였다[16]. 동일 원본 영상이 서로 다른 세트에 중복되지 않도록 ID를 기준으로 분리하여 데이터 누수를 방지하였다. 시험(test) 세트는 영상 20,172장과 GT 41,472건으로 구성되며, 클래스별 분포는 Table 2에 요약된다. Fixed_Wing, Fishing_Boat, Warship의 비중이 60% 이상을 차지하고, 군 경계 감시의 핵심 표적인 Person은

1,069건(2.6%)으로 상대적으로 적다. Bird, Person 그리고 Leaflet 세 클래스는 평균 bbox의 작은 변이 30화소 이하의 소형 객체이며, 전체 GT의 73%가 입력 해상도 576×576 기준으로 한 변 길이가 32화소 미만인 소형 객체이다.

Table 2. GT distribution by class

Class	GT Count	Ratio	Mean bbox
Fixed_Wing	8,487	20.5%	≈ 90×40px
Fishing_Boat	8,508	20.5%	≈ 120×80px
Warship	7,976	19.2%	≈ 250×120px
UAV	5,708	13.8%	≈ 50×30px
Rotary_Wing	2,844	6.9%	≈ 80×60px
Merchant_Ship	2,417	5.8%	≈ 200×100px
Bird	1,574	3.8%	≈ 24×24px
Trash_Bomb	1,445	3.5%	≈ 60×60px
Leaflet	1,444	3.5%	≈ 28×40px
Person	1,069	2.6%	≈ 35×55px

학습은 NVIDIA RTX 5090 32 GB 환경에서 AdamW 최적화 알고리즘을 적용한다. 초기 학습률(learning rate)은 1×10^{-4} , 배치 크기는 16, 최대 학습 횟수(epoch)는 100으로 설정한다. 학습률 조정은 코사인 감쇠(cosine annealing) 스케줄을 적용하고, 학습 초기 1 epoch 동안 점진적으로 학습률을 증가시키는 준비 학습(warm-up)을 적용한다. 가중치 감쇠(weight decay)는 1×10^{-4} 로 설정하고, 데이터 증강에는 모자이크(mosaic), 자동 증강 정책(rand augment), 색상 변환(color jitter)을 사용한다. 검증 과정(validation)에서 mAP가 10 epoch 연속 개선되지 않으면 조기 종료(early stopping)한다. 이때 대기 횟수(patience)는 10으로 설정한다. 시험은 동일한 GPU로 PyTorch FP32 정밀도로 수행하였고, 온디바이스 성능 평가는 NVIDIA Jetson AGX Orin 64 GB에서 TensorRT FP16 정밀도로 수행한다.

4.2. 성능 시험 결과 및 분석

성능 평가는 mAP를 적용하였으며, 시험 결과는 Table 3과 같다. Table 3은 전체 클래스에 대한 mAP@50:95와 Person 클래스에 대한 AP@50:95를 비교한 결과이다. mAP@50:95는 데이터셋의 모든 클래스를 대상으로 한 평균 탐지 성능을 의미하고, Person AP@50:95는 원거리 소형 객체 성격이 강한 Person 클래스만을 대상으로 한 평균 탐지 성능이다.

Table 3. Performance comparison on military border dataset

Model	mAP @50:95	Person AP@50:95
YOLOv11-N	0.837	0.290
YOLOv11-S	0.868	0.389
YOLOv11-M	0.870	0.374
YOLOv11-L	0.874	0.380
YOLOv12-N	0.825	0.215
YOLOv12-S	0.854	0.301
YOLOv12-M	0.867	0.370
YOLOv12-L	0.870	0.369
RF-DETR-Base	0.902	0.673
SOD-NWD	0.907	0.694
SOD-SCA	0.904	0.704
SOD-SCA+NWD	0.906	0.713

YOLOv11과 YOLOv12의 mAP@50:95는 0.825~0.874 범위이고[17-18], RF-DETR-Base는 0.902로 CNN 계열 모델보다 높은 성능을 보인다. 특히 Person 클래스에서 YOLOv11과 YOLOv12의 Person AP@50:95는 0.215~0.389 범위에 머무는 반면, RF-DETR-Base는 0.673을 기록하여 상대적으로 우수한 성능을 보인다. 이를 통해 본 데이터셋에서는 CNN 계열의 YOLO 모델에 비해 트랜스포머 기반 객체 탐지 모델이 원거리 소형 객체 탐지에서 더 높은 표현력을 보임을 확인할 수 있다. 또

한, Area Attention을 적용한 YOLOv12는 동일 스케일의 YOLOv11 대비 동등하거나 낮은 성능을 보인다[18]. YOLOv12의 국소 영역 어텐션은 일반적인 실시간 객체 탐지에서는 효과적일 수 있으나, 본 평가 데이터셋과 같이 원거리 소형 객체가 많은 환경에서는 직접적인 성능 개선으로 이어지지 않았다. 반면 RF-DETR의 DINOv2 ViT 백본은 전역 self-attention을 통해 패치 수준의 소형 객체 단서를 더 안정적으로 반영하여 상대적으로 우수한 탐지 결과를 보인다.

제안 모델의 ablation 결과를 보면 SOD-NWD는 RF-DETR-Base 대비 mAP@50:95를 0.902에서 0.907로 개선하고, Person AP@50:95를 0.673에서 0.694로 개선한다. 이는 NWD가 헝가리안 정합 단계에서 작은 객체의 BBox 정합 안정성을 보완한 결과로 해석할 수 있다. SOD-SCA는 mAP@50:95 0.904, Person AP@50:95 0.704를 기록하여 SCA만 적용하더라도 RF-DETR-Base 대비 Person 클래스 성능이 향상됨을 보인다. 최종 모델인 SOD-SCA+NWD는 mAP@50:95 0.906, Person AP@50:95 0.713을 기록한다. 전체 mAP 개선 폭은 크지 않지만, Person AP@50:95는 RF-DETR-Base 대비 +0.040 향상되어 제안 기법이 원거리 소형 객체의 평균 탐지 성능을 개선함을 확인할 수 있다.

SOD-NWD와 SOD-SCA는 서로 다른 방식으로 성능 향상에 기여한다. SOD-NWD는 mAP@50:95를 0.907로 가장 높은 탐지 성능을 보인다. SOD-SCA는 Person AP@50:95를 0.704로 향상시켜 소형 객체 후보에 대한 특징을 보강하는 효과가 있다. 따라서, 제안 소형 객체 탐지 모델은 군 경계 감지에서 중요한 원거리 소형 객체 탐지 성능이 개선된 것을 확인할 수 있다.

Figure 4는 평가 데이터셋의 10개 클래스에 대한 오탐지(False Positive, FP)의 원인을 중복 탐지(FP_duplicate), 배경 오탐지(FP_background), 그리고 위치 오탐지(FP_localization)으로 분류한 결과이다.

중복 탐지는 하나의 객체에 대하여 중복 탐지하는




Figure 4. FP cause classification by experiment configuration

것이고, 배경 오탐지는 배경을 객체로 탐지하는 것이다. 위치 오탐지는 실제 객체 근처에서 탐지하였으나, BBox의 위치가 부정확한 것으로 IoU가 0.5 미만인 것을 나타낸다.

RF-DETR-Base의 오탐지는 121건이고, SOD-SCA+NWD는 74로 38.8% 감소하였다. FP_background는 85건에서 48건으로, FP_localization은 34건에서 26건으로 감소하였으며, FP_duplicate는 2건에서 0건으로 제거되었다.

Figure 5는 RF-DETR-Base 모델이 탐지하지 못한 Person 객체를 SOD-SCA+NWD가 탐지한 결과를 보여준다. 제안하는 SOD 파이프라인은 ViT 패치 해상도만으로 포착하기 어려운 Person 클래스 객체의 공간적 특징을 stride-8 CNN 분기와 선택적 교차 어텐션으로 보완하여 전경과 배경의 판별력을 개선한다.

Figure 6은 제안하는 소형 객체 탐지 모델 적용에서 발생하는 미탐지와 오탐지 결과이다. 첫 번째 열에는 입력 영상에 대하여 GT와 탐지 결과 BBox를 표시한 것이고, 두 번째 열은 미탐지 또는 오탐지 영역을 확대한 것이다. (a)는 선상의 사람이 탐지되지 않은 사례로써 소형 객체인 사람(Person)의 특징과 선박과 유사하여 탐지되지 않았다. (b)는 파도를 새(Bird)로 오탐지한 결과로써 파도의 텍스처와 새와



Figure 5. Person detection results of RF-DETR-Base(left) and SOD-SCA+NWD(right)




Figure 6. Results of false detection, (a) false negative example (b) false positive example

유사하여 새로 탐지한 것으로 판단된다. EO-IR 다중모드 탐지와 결합한다면 미탐지와 오탐지를 개선할 수 있을 것으로 예상된다.

4.3. 온디바이스 AI 분석

본 논문에서는 제안하는 객체 탐지 모델을 온디바이스 AI 환경에서 탐지 성능과 처리 속도를 비교 분석한다. NVIDIA Jetson AGX Orin 64GB에서 TensorRT FP16 기준으로 성능과 처리 속도를 비교한다.

처리 속도와 탐지 성능을 비교한 결과는 Table 4에 나타낸다. RF-DETR-Base는 1프레임 처리 시간이 6.97ms로 143.3FPS를 기록하였고, SOD-SCA+NWD는 7.46ms, 134.0FPS를 기록하였다. SOD-SCA+NWD는 RF-DETR-Base 대비 약 7.0%의 지연 증가가 있으나, 실시간 처리 기준을 만족한다.

Table 4. AGX Orin TensorRT FP16 deployment analysis

Model	TensorRT FP16(ms)	FPS
RF-DETR-Base	6.97	143.3
SOD-SCA+NWD	7.46	134.0

5. 결론

본 연구는 군 경계 감시 환경에서 원거리 소형 객체 탐지 성능을 개선하기 위해 SCA와 NWD를 결합한 SOD-SCA+NWD 모델을 제안하였다. SCA는 DINOv2 self-attention map을 이용해 소형 객체 후보 영역의 CNN 토큰만 선택적으로 ViT 특징에 융합하고, NWD는 헝가리안 정합 단계에서 소형 객체의 BBox 정합 안정성을 높인다.

시험 결과, SOD-SCA+NWD는 mAP@50:95 0.906, Person AP@50:95 0.713을 기록하였다. RF-DETR-Base 대비 mAP@50:95는 0.004, Person AP@50:95는 0.040 향상되었고, 전체 FP는 121건에서 74건으로 38.8% 감소하였다. 또한, Jetson AGX Orin 64 GB에서 7.46 ms, 134.0 FPS의 처

리 속도를 보여 실시간 온디바이스 적용 가능성을 확인하였다.

향후 장면 복잡도에 따라 Top-K 토큰 선택 비율을 동적으로 조정하고, 연속 프레임에 대한 객체 추적과 EO-IR 데이터를 추가하여 해무, 저조도, 배경 텍스처가 복잡한 감시 환경에서의 탐지 성능 개선 연구를 하고자 한다.

사 사

본 논문은 2025 년도 정보통신기획평가원의 정보보호핵심원천기술개발사업, 한미조인트콜 선진국제공동연구(과제명: 멀티-뷰 기반 군중이상상황 자율대응을 위한 AI Crowd Dynamics 기술 및 실증시스템 개발, RS-2024-00460386)의 지원으로 수행되었음. 본 논문 원고 작성 과정에서 생성형 인공지능 Anthropic Claude(claude.ai)를 사용하여 문장 교정, 영문 초록 작성 및 논문 내 흐름도, 이미지 생성 보조 도구로 활용하였으며, 실험 설계, 데이터 수집 및 분석, 결과 해석은 저자가 수행하였음.

참고문헌

- Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020). End-to-end object detection with transformers. In A. Vedaldi, H. Bischof, T. Brox, & J.-M. Frahm (Eds.), *Computer vision – ECCV 2020* (Lecture Notes in Computer Science, Vol. 12346, pp. 213–229). Springer. https://doi.org/10.1007/978-3-030-58452-8_13
- Zhu, X., Su, W., Lu, L., Li, B., Wang, X., & Dai, J. (2021). Deformable DETR: Deformable transformers for end-to-end object detection. In *Proceedings of the International Conference on Learning Representations* (ICLR 2021).
- Zhang, H., Li, F., Liu, S., Zhang, L., Su, H., Zhu, J., Ni, L., & Shum, H.-Y. (2023). DINO: DETR with improved denoising anchor boxes for end-to-end object detection. In *Proceedings of the International Conference on Learning Representations* (ICLR 2023).
- Zong, Z., Song, G., & Liu, Y. (2023). DETRs with collaborative hybrid assignments training. *2023 IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, pp. 6725–6735. <https://doi.org/10.1109/ICCV51070.2023.00621>
- Zhao, Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). DETRs beat YOLOs on real-time object detection. *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2024)*, pp. 16965–16974. <https://doi.org/10.1109/CVPR52733.2024.01605>
- Robinson, I., Robicheaux, P., Popov, M., Ramanan, D., & Peri, N. (2025). *RF-DETR: Neural architecture search for real-time detection transformers* (arXiv: 2511.09554). arXiv. <https://doi.org/10.48550/arXiv.2511.09554>
- Oquab, M., Darcet, T., Moutakanni, T., Vo, H. V., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., Synnaeve, G., Xu, H., Jegou, H., Mairal, J., Labatut, P., Joulin, A., & Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In D. Fleet, T. Pajdla, B. Schiele, & T. Tuytelaars (Eds.), *Computer vision – ECCV 2014* (Lecture Notes in Computer Science, Vol. 8693, pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48
- Chen, Z., Duan, Y., Wang, W., He, J., Lu, T., Dai, J., & Qiao, Y. (2023). Vision transformer adapter for dense predictions. In *Proceedings of the International Conference on Learning Representations* (ICLR 2023).
- Wang, J., Xu, C., Yang, W., & Yu, L. (2021). *A normalized Gaussian Wasserstein distance for tiny object detection* (arXiv:2110.13389). arXiv. <https://doi.org/10.48550/arXiv.2110.13389>
- Xu, C., Wang, J., Yang, W., Yu, H., Yu, L., & Xia, G.-S. (2022). Detecting tiny objects in aerial images: A normalized Wasserstein distance and a new benchmark.

- ISPRS Journal of Photogrammetry and Remote Sensing*, 190, 79-93. <https://doi.org/10.1016/j.isprsjprs.2022.06.002>
- [12] Zhu, P., Wen, L., Du, D., Bian, X., Fan, H., Hu, Q., & Ling, H. (2022). Detection and tracking meet drones challenge. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(11), 7380-7399. <https://doi.org/10.1109/TPAMI.2021.3119563>
- [13] Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). Emerging properties in self-supervised vision transformers. *2021 IEEE/CVF International Conference on Computer Vision (ICCV 2021)*, pp. 9630-9640. <https://doi.org/10.1109/ICCV48922.2021.00951>
- [14] Wu, Y., & He, K. (2018). Group normalization. In V. Ferrari, M. Hebert, C. Sminchisescu, & Y. Weiss (Eds.), *Computer vision – ECCV 2018* (Lecture Notes in Computer Science, Vol. 11217, pp. 3-19). Springer. https://doi.org/10.1007/978-3-030-01261-8_1
- [15] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *2017 IEEE International Conference on Computer Vision (ICCV 2017)*, pp. 2999-3007. <https://doi.org/10.1109/ICCV.2017.324>
- [16] AI Hub. (2024). 군 경계 작전 환경 내 인식 데이터. <https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71858>
- [17] Khanam, R., & Hussain, M. (2024). *YOLOv11: An overview of the key architectural enhancements* (arXiv: 2410.17725). arXiv. <https://doi.org/10.48550/arXiv.2410.17725>
- [18] Tian, Y., Ye, Q., & Doermann, D. (2025). *YOLOv12: Attention-centric real-time object detectors* (arXiv: 2502.12524). arXiv. <https://doi.org/10.48550/arXiv.2502.12524>